

Primeros 90 días · Especialista en Observabilidad y Automatización

Andina Financiera · Dirección de Operaciones de TI · Propuesta basada en el caso PortalPagos

Punto de partida (medido en los retos 1 a 4)

Indicador	Hoy (semana del 14-sep)	Probado en el laboratorio (Reto 3)	Meta a 90 días (producción)
Quién detecta los incidentes	Los clientes (0 % detectado antes del primer ticket)	Una alerta, a ~1–1,7 min	≥ 80 % detectados antes del primer ticket
MTTD: cuánto tardamos en enterarnos	Nunca: el NOC no alertó; avisaron los clientes	1,0–1,7 min	< 5 min
MTTR: cuánto tardamos en recuperar el servicio	101 min desde el primer error	2,3–3,3 min (pool caído, automático)	< 15 min en fallas conocidas · < 60 min en el resto
Disponibilidad real	98,57 % (el NOC reportaba 100 %)	Medida por una sonda sintética	≥ 99,9 % mensual en operaciones de pago (SLO acordado con negocio; requiere que desarrollo haya corregido la fuga de memoria)
Riesgos abiertos	Disco lleno ~22-sep, fuga de memoria, contraseña en texto plano	Mecanismos probados en el laboratorio (reciclaje por memoria, retención por presión de disco, mantenimiento sin contraseña)	Cerrados en producción en el día 10

Las metas son un punto de partida: el laboratorio prueba que el mecanismo funciona, no el número de producción. Se confirman con las 2 primeras semanas de datos reales (iniciativa 2); el 80 % deja margen a incidentes que ninguna señal anticipa, como un error funcional sin impacto en métricas.

Iniciativas, priorizadas por impacto, esfuerzo y riesgo

#	Iniciativa	Impacto	Esfuerzo	Riesgo	Cuándo
1	Cerrar los riesgos que ya tienen fecha. El día 1 (el disco se llena el día 2): liberar C: y bajar el log a <i>Information</i> ; copiar fuera los dumps del 18-sep para desarrollo; rotar la contraseña de <code>svc_mantenimiento</code> ; instalar el mantenimiento del Reto 2 (gMSA, auditoría verificada); y reemplazar el <code>iisreset</code> por reciclaje por memoria , sin quitar la protección mientras exista la fuga	Muy alto: evita la próxima caída, que ya tiene fecha	Bajo: el mantenimiento nuevo ya está escrito y probado	Medio: va con ventana de cambio y rollback, porque la tarea vieja queda deshabilitada, no borrada	Días 1–10
2	Detección desde el cliente. Azure Monitor Agent (Azure Arc si el servidor es on-prem) y sonda sintética externa de las operaciones de pago, sin limitarse a <code>/health</code> . Las 6 alertas del Reto 3 con umbrales calibrados contra 2 semanas de datos reales, más un tablero para Dirección y otro para el NOC. Se retiran “ping OK” y la revisión semanal manual	Muy alto: cambia quién se enteró primero	Bajo-medio	Bajo: solo observa	Días 5–30
3	Despliegues con red de seguridad. Una verificación automática 24 h después de cada despliegue: memoria, p95 y 5xx frente a la semana anterior, con el despliegue marcado en el tablero. Todo cambio de infraestructura, por ejemplo el proxy del 16-sep, pasa por un ticket. Junto con desarrollo: corregir <code>SesionPagoCache</code> y un <code>/health</code> profundo	Alto: la causa raíz del 18-sep fue un cambio no vigilado	Medio: hay que coordinar con desarrollo	Bajo	Días 20–60
4	Auto-remediación con salvaguardas para las fallas que se repiten: pool caído (Reto 3), disco y servicio detenido. Dos semanas en modo “sugerir” , en las que el runbook decide pero no ejecuta y una persona confirma (en la prueba en vivo del laboratorio aparecieron dos defectos que las pruebas automáticas no detectaron: una escalada falsa tras cada recuperación y un mantenimiento que fallaba con el log abierto por IIS); después pasa a modo automático, con límite de intentos, anti-bucle, escalamiento y trazabilidad	Alto: MTTR de horas a minutos	Medio	Medio, controlado por las salvaguardas y por empezar en modo sugerencia	Días 40–75
5	Triaje con IA y post-mortems sin culpables. El triaje del Reto 4 adjunta a cada alerta un resumen con evidencia verificada; solo sugiere y nunca ejecuta. Cada incidente Sev1/Sev2 cierra con un post-mortem y acciones con dueño y fecha: se acaba “causa: por determinar”	Medio: acelera la primera respuesta y deja aprendizaje	Bajo	Bajo: el validador rechaza lo que no tenga sustento	Días 50–90

Cómo se mide el éxito

Se mide todo con datos, no con percepción.

- **Cada mes, en el tablero de Dirección:** MTTD, MTTR y “% detectado antes del primer ticket”, calculados al cruzar las alertas con los tickets de la mesa de servicio.
- **Disponibilidad:** según la sonda sintética frente al SLO.
- **Horas de trabajo manual eliminadas:** durante las semanas 1 y 2 se toma una línea base de las tareas repetitivas (revisión semanal del NOC, reinicios manuales, limpieza de disco, cierre de tickets duplicados) y en el día 90 se compara.
- **Calidad del ruido:** < 5 alertas no accionables por semana. Si una alerta no lleva a ninguna acción, se ajusta o se elimina. La alerta de memoria saltará casi a diario mientras exista la fuga y no cuenta como ruido: cada disparo es evidencia para desarrollo; al corregirla, se sube su umbral o se apaga.
- **Cambios:** el 100 % de los despliegues con verificación de 24 h y el 100 % de los cambios de infraestructura con ticket.

Hitos de control: día 10, riesgos con fecha cerrados · día 30, detección desde el cliente funcionando y umbrales calibrados · día 60, verificación de despliegues y remediación en modo sugerencia · día 90, metas de la tabla y revisión con la directora.

Lo que necesito que mi líder destrabe

- 1. **Acceso de lectura** a los logs y métricas de producción. Si el servidor es on-prem, aprobación para instalar **Azure Arc + AMA**.
- 2. **Una gMSA** con escritura en el share de auditoría, coordinada con el equipo de directorio activo.
- 3. **Ventanas de cambio** para la iniciativa 1, con la dueña del servicio informada.
- 4. **Un acuerdo con desarrollo** sobre la corrección de la fuga, el nivel de log, `/health` profundo y la verificación post-despliegue como requisito para salir a producción.
- 5. **El SLO de negocio:** qué significa “disponible” para PortalPagos y cuál es el objetivo. Lo decide la directora, no yo.
- 6. **Presupuesto** de Azure Monitor y Azure OpenAI (decenas de dólares al mes a este volumen) y una **política de datos** con Seguridad: qué se puede enviar a un modelo y con qué enmascaramiento.

Lo que NO haría en estos 90 días (y por qué)

No haría	Por qué
Quitar el reinicio nocturno sin reemplazo	Con la fuga activa, el portal cae en ~1,5 días (Reto 1). Primero el reciclaje por memoria, después la corrección
Auto-remediar reinicios de IIS completo o de la VM, o dejar que la IA ejecute acciones	El impacto de equivocarse es mayor que el de esperar unos minutos a una persona. La IA sugiere y la automatización solo hace lo acotado y probado
Comprar otra herramienta de observabilidad	Azure Monitor ya cubre lo necesario. El problema no era de herramienta sino de qué se miraba (<code>/health</code> y ping)
Alertar por todo (DCOM 10016, Schannel, 404 de escáneres)	Es ruido que entrena a la gente a ignorar las alertas. El ticket T-10261 culpó a DCOM sin evidencia
Enviar datos reales de clientes a un modelo sin enmascarar	Riesgo regulatorio en una entidad financiera. Primero va la política de datos (punto 6)
Corregir yo el código de la aplicación	Le corresponde a desarrollo. Mi parte es que el defecto se vea antes, se contenga y no vuelva a salir sin verificación